

지산학캡스톤디자인 프로젝트 수행계획서

학생 팀별 작성용

프로젝트 수행팀 현황					
수행 학기	■ 2025년 9월~2025년 12월				
프로젝트명	■ LLM 기반 스미싱 탐지·차단 서비스				
팀명	■ Fremen				
교과목명	■ 지산학캡스톤디자인2				
팀장	학과	학번	성명	연락처	E-mail
	정보통신공학과	2021112061	임현우	010-3098-1575	dlagusdn0218@gmail.com
팀원	정보통신공학과	2021112040	윤찬혁	010-4803-5079	ych758@naver.com
	정보통신공학과	2021112092	조효동	010-3223-9978	whgyehdjhd@naver.com
지도교수	소속	SW교육원		넥스브이	
	성명	이길섭 교수		송환구 교수	
멘토	소속	(주)넥스브이		송환구 연구소장	

프로젝트

프로젝트 개요	● 프로젝트에 대한 개요 설명 : 1. 아이디어 소개 및 주제 선정 배경 본 프로젝트의 주제는 <LLM 기반 스팸싱 탐지·차단 서비스> 입니다.. 문자 및 메신저를 통해 전달되는 스팸싱 메시지를 실시간으로 탐지하고 사용자가 즉각 대응할 수 있는 환경을 제공하는 것을 목표로 합니다. 단순 차단을 넘어, AI가 “왜 위험한지”를 설명해줌으로써 사용자가 이해하고 능동적으로 대처할 수 있는 새로운 보안 서비스를 제시합니다. 2. 프로젝트의 필요성 최근 스팸싱은 연령과 관계없이 광범위하게 발생하고 있으며, 특히 시니어·청소년 등 디지털 보안 취약 계층의 피해가 두드러집니다. 기존 스팸싱 탐지 기술은 패턴 기반에 머물러 있어, 새로운 유형의 공격에는 취약합니다. 또한, 사용자가 스스로 스팸싱 여부를 판별하기 어렵고, 메시지를 수신한 이후 즉각적으로 어떤 행동을 취해야 하는지 안내가 부족하여 피해로 이어지는 사례가 빈번합니다. 따라서 더욱 지능적이고 사용자 친화적인 스팸싱 방어 체계의 필요성이 점차 증대되고 있습니다. 3. 해결방향 본 프로젝트는 LLM을 활용하여 문자·메신저로 전달되는 스팸싱 메시지를 실시간으로 탐지하고, 폰에서 빠르게 위험 여부를 분류합니다. 서버 LLM은 탐지된 메시지가 “왜 위험한지”에 대한 상세한 설명을 제공하여 사용자의 이해를 돕습니다. 사용자는 이 정보를 바탕으로 스팸싱 메시지를 즉시 차단, 신고, 공유하거나 은행 지급정지 안내를 실행할 수 있도록 지원합니다. 주요 사용자층은 스팸싱 피해가 잦은 20~40대 일반 스마트폰 사용자와 디지털 보안에 익숙하지 않은 시니어·청소년과 같은 취약 계층을 포함하며, 장기적으로는 KISA, 금융사 보안팀 등 보안 담당자 및 기관으로 확장할 계획입니다.
--------------------	--

1. 개발 배경 및 필요성 :

- 스미싱 피해 폭증

2024년 스미싱 범죄 발생 건수는 약 4,396건으로, 2020년의 822건과 비교했을 때 약 5배 가까이 증가하였다. 같은 기간 피해액 역시 11억원에서 546억원으로 약 50배 이상 늘어나며 피해의 심각성이 드러났다. 특히 2024년 상반기 동안 접수된 스미싱 피해 신고 건수만 해도 약 88만 7,800건에 달해, 사회적으로 큰 파장을 일으켰다.

- 탐지 건수의 급격한 증가

한국인터넷진흥원(KISA)의 집계에 따르면, 2023년 스미싱 탐지 건수는 약 50만 건 수준이었으나 2024년 8월까지 이미 109만 2,838건을 기록하며 두 배 이상 증가하였다. 특히 2022년부터 2024년 사이에 접수된 스미싱 유형 중 기관 사칭이 전체의 절반 이상을 차지하며 가장 빈번한 수법으로 나타났다.

- 주요 사칭 유형의 변화 및 정교화

2025년 1분기 보안 보고서에서는 기관 사칭 유형이 가장 높은 비중을 차지했으며, 이어서 단기 알바 위장, 가족·지인 사칭 등이 급격히 증가한 것으로 나타났다. 특히 단기 알바 사칭 유형은 이전 분기 대비 무려 285% 증가하여 사회적 문제로 주목받았다. 또 다른 통계에서는 스미싱 메시지의 문구 중 개인정보 유출·수집을 사칭한 경우가 전체의 37%를 차지해 가장 많았으며, 금융기관 사칭이 19%, 이벤트나 광고로 위장한 유형이 뒤를 이었다.

- 신종 수법 출현과 사용자 취약성 확대

최근에는 “USIM 재고 도착 알림”과 같은 통신사 관련 안내 메시지를 사칭하여 악성 앱 설치를 유도하는 새로운 수법이 등장하였다. 또한 QR 코드 변조를 통한 큐싱(Qshing) 피해도 꾸준히 증가하고 있으며, 피해 연령대 역시 점차 고령층인 50~60대 이상으로 확대되는 양상이 뚜렷하다. 이는 디지털 보안에 상대적으로 취약한 계층이 주요 공격 대상이 되고 있음을 보여준다.

- 정책적·사회적 요구 증가

정부와 관계기관은 명절이나 연말정산 시즌과 같이 특정 시기에 집중적으로 발생하는 스미싱 공격에 대응하기 위해 주의보를 발령하고 있다. 과태료나 범칙금 조회, 세금 환급 위장, 상품권 지급을 사칭하는 메시지가 대표적인 유형이다. 그러나 현재의 대응 체계는 대부분 사후 신고와 차단에 그치고 있어, 탐지 건수가 폭증하는 상황에서 실질적인 예방 효과는 제한적이라는 비판이 커지고 있다. 무엇보다 사용자 입장에서 왜 해당 메시지가 위험한지 이해할 수 있는 설명과 즉각적인 대응 방안이 부족하다는 점이 문제로 지적된다.

- 필요성 요약

종합하면, 최근 2~3년간 스미싱 피해와 탐지 건수가 폭발적으로 증가하였고, 사칭 유형과 기법은 갈수록 정교해지고 다양화되고 있다. 특히 고령자나 보안 지식이 낮은 일반 사용자를 중심으로 피해 위험이 커지고 있으며, 기존 대응 방식은 사후 처리 위주로 한계를 드러내고 있다. 따라서 본 프로젝트가 실시간으로 스미싱을 탐지하고, 사용자에게 명확한 이유와 함께 예방 가능한 대응 방안을 제공하는 것은 현 시점에서 시급하고 필수적인 과제라 할 수 있다.

2. 선행기술 및 사례 분석 :

(1) 통신사 스미싱 차단 서비스

국내 주요 통신사(SK텔레콤, KT, LGU+)는 문자 필터링, URL 차단, 신고 연계 등의 기능을 제공하고 있다. 그러나 이들 서비스는 대부분 블랙리스트 기반 탐지 방식에 의존하고 있어, 새로운 유형의 공격인 제로데이 스미싱에는 대응이 늦다는 한계가 있다. 또한 탐지 이유를 사용자에게 구체적으로 설명하지 않아 신뢰성과 투명성이 부족하고, 사용자가 메시지의 위험성을 이해하지 못한 채 결국 링크를 클릭하는 경우도 발생한다.

(2) 금융권 사례: 카카오뱅크

카카오뱅크는 자체 보안 시스템을 통해 의심 링크 클릭 시 경고 페이지를 노출하고, 은행 앱 내에서 지급정지 안내를 제공하는 기능을 운영하고 있다. 특히 금융사 중 최초로 인공지능 기반 탐지 모델을 일부 적용하여 단순 패턴 탐지보다 높은 정밀도를 확보한 점이 주목된다. 그러나 이러한 서비스는 자사 애플리케이션 내부에 국한되어 있어, 사용자 단말 전체의 SMS나 메신저에 대한 방어까지는 제공하지 못한다. 본 프로젝트는 카카오뱅크의 설명 가능한 경고 화면이라는 강점을 참고하되, 이를 범용 LLM과 RAG 기반으로 발전시켜 스마트폰 전역에서 동작하는 시스템으로 확장하고자 한다.

(3) 빅테크 및 보안 기업 기술

구글은 안드로이드 기본 메시지 앱에서 스팸 및 피싱 메시지 필터링 기능을 제공하고 있으나, 영문 데이터를 중심으로 학습된 탓에 한국어 스미싱 탐지 정확도가 낮은 문제가 있다. 또한 안랩과 이스트시큐리티 등 국내 보안 기업들은 백신 앱과 URL 차단 기능을 결합한 서비스를 제공하고 있지만, 여전히 행위 기반 분석보다는 사후 대응에 머무르는 경우가 많아 즉각적인 예방 효과에는 한계가 있다.

(4) 본 프로젝트의 차별성

기존 선행 기술들이 사후 차단과 경고에 중점을 두고 있는 반면, 본 프로젝트는 실시간 판별을 통한 사전 예방에 초점을 맞춘다. 특히 LLM과 RAG를 결합하여 메시지를 분석함으로써 단순한 차단을 넘어 사용자에게 왜 해당 메시지가 위험한지에 대한 설명을 제공한다. 이를 통해 통신사의 URL 차단 한계를 보완하고, 금융사의 지급정지 안내 기능을 스마트폰 전역으로 확장하며, 보안 앱에서 부족했던 사용자 이해를 돕는 해설 기능까지 강화하는 차별적인 가치를 제공할 수 있다.

목표 및
내용

● 개발목표 :

본 프로젝트의 목표는 대규모 언어모델(LLM)을 활용한 스미싱 탐지·차단 시스템을 구현하는 것이다. 최근 스미싱은 단순 스팸이 아니라 실제 기관이나 상사를 사칭하고, 업무 맥락에 맞춘 정교한 형태로 발전하여 기존의 키워드 기반 필터나 블랙리스트만으로는 탐지가 어렵다. 본 프로젝트는 사용자의 휴대폰으로 수신되는 문자와 메신저 메시지를 실시간으로 분석하여, 정상 / 의심 / 위험으로 분류하고, 위험 메시지에 대해서는 서버의 LLM이 “왜 위험한지”를 설명하여 사용자가 즉시 이해하고 대응할 수 있도록 지원하는 것을 핵심 목표로 한다.

본 프로젝트의 핵심 목표를 위해 고려되어야 할 사항들은 다음과 같다. 먼저, 정확한 탐지를 위해 룰 기반 탐지와 LLM 분석을 결합하여 단순 키워드 필터를 넘어 맥락을 이해하는 고도화된 판별 방식을 제공해야 한다. 둘째, 사용자가 쉽게 납득할 수 있도록 RAG 기반 설명 기능을 추가하여, “보낸 사람 주소가 회사 도메인과 유사하지만 다름”, “과도한 긴급 송금 요구가 포함됨”과 같은 근거를 제시해야 한다. 셋째, 실제 환경에서 활용성을 높이기 위해 푸시 알림, 차단, 신고, 공유 등 후속 행동까지 연결되는 기능이 제공되어야 한다.

이러한 요소들을 얼마나 효과적으로 구현하느냐, 그리고 사용자가 직관적으로 서비스를 받아들이고 행동으로 옮길 수 있도록 UX를 설계하느냐가 본 프로젝트의 난이도이자 도전 요소이다. 또한 결과물의 완성도 측면에서는 메시지 탐지·설명·차단·신고의 전 과정을 하나의 앱 서비스로 통합하고, 서버 백엔드(Spring Boot, PostgreSQL 기반)가 안정적으로 탐지와 데이터 처리를 수행하도록 개발하는 것이 목표이다.

결론적으로, 본 프로젝트를 통해 경제적 측면에서는 스미싱 피해로 인한 금전적 손실을 줄이고, 사회적 측면에서는 일반 사용자와 디지털 취약 계층(시니어·청소년)의 보안 인식을 향상시키며, 산업적 측면에서는 기업 보안팀이나 금융사가 손쉽게 연계할 수 있는 차세대 보안 솔루션을 제시하는 것을 개발의 궁극적 목표로 한다.

● 개발내용 :

최종 설계 결과물의 형태

- 소프트웨어 프로토타입 형태로 제공
 - 안드로이드 앱 (클라이언트): 사용자 단말에서 스미싱 메시지를 감지하고 결과를 확인할 수 있는 앱
 - 백엔드 서버 (Spring Boot 기반): 스미싱 분석·판별 및 사용자 관리, 데이터 저장/조회 API 제공
 - AI 분석 모듈 (LLM 연동): 추출된 메시지 텍스트를 기반으로 스미싱 여부

를 분석

- 데이터베이스 (MySQL, Docker 환경): 사용자 정보, 차단 번호, 탐지 로그, 분석 결과 저장
- Firebase 서비스: 푸시 알림, 간단 로그인, 사용자 분석 등 부가 기능 제공

▪ 대표 기능 및 하위 기능

1. 회원가입/로그인 기능

- 아이디/비밀번호/이메일 유효성 검사
- 소셜 로그인 지원

2. 스미싱 탐지 기능 (핵심)

- 문자 내용 추출 및 서버 전송
- URL 및 특정 단어 탐지
- AI 기반 위험 점수 계산

3. 경고 알림 기능


- 알림창 배너 표시
- 위험도 단계(정상/의심/위험) 구분
- 상세 분석 결과 제공

4. 차단 번호 관리 기능

- 차단 번호 추가 및 삭제
- 차단 목록 조회 및 공유

5. 친구 기능 (서브)

- 친구와 차단 목록 공유
- 비슷한 번호 차단 추천



● 대안 도출 및 구현 계획 :

본 프로젝트의 가장 큰 어려움은 스미싱·스팸 탐지 모델 학습을 위한 실제 데이터의 부족이다.

이를 해결하기 위해 다양한 대안을 검토하였으며, 최종적으로 데이터 증강 기법을 활용하는 방안을 선택하였다.

1. 대안 및 비교 분석

- 공개된 공신력 있는 데이터셋 활용 (예: KISA, Kaggle 등)
- 웹 크롤링을 통한 샘플 확보
- 데이터 증강 기법 적용 (텍스트 변형, 역번역, 동의어 치환 등)

이 중에서 공개 데이터와 증강 데이터의 결합이 가장 현실적이고 효과적인 방안으로 판단하였다.

2. 제한 요소 고려

- 개인정보 보호 및 보안 문제로 인해 실제 개인정보가 포함된 데이터는 사용할 수 없음
- 텍스트 데이터 특성상 단순 중복이나 랜덤 변형은 학습 성능을 저하시킬 위험 존재

3. 선택된 해결 방안

- 한국어 스미싱 공개 데이터셋을 기반으로 데이터 증강 기법을 적용
- 증강 방식: 역번역(Back-translation), 동의어 치환, 문장 순서 섞기, 랜덤 문자 삽입/삭제 등
- 원본 데이터와 증강 데이터를 결합하여 학습 데이터의 다양성과 신뢰성을 동시에 확보

4. 구현 계획

- 주요 기능 구현 방법: LLM 기반 분류기를 증강 데이터로 Fine-tuning
- 데이터 정의 및 자료 구조: JSON/CSV 형식으로 `{"text": "...", "label": 0 or 1}` 구조 설계
- 전체 알고리즘 흐름
 - 1) 원본 데이터 수집
 - 2) 증강 모듈 적용 (다양한 기법 활용)
 - 3) 증강 데이터셋 저장 및 전처리
 - 4) 학습·검증·테스트 데이터 분할
 - 5) 모델 학습 및 성능 평가

● **설계의 현실적 제한요소(제약조건) :**

비용 및 제품화 고려사항

- 본 프로젝트는 연구·학습 목적의 프로토타입 개발을 목표로 하므로 상용 수준의 인프라 구축은 어렵다.
- 서버 운영은 클라우드 무료 티어 (AWS, GCP 등) 또는 Docker 기반 로컬 환경을 활용하여 비용 최소화.
- AI 모델 분석은 Hugging Face Hub의 사전 학습된 모델 API를 활용하여 초기 비용을 절감.
 - 장점: 직접 모델을 학습하지 않아도 되므로 GPU 인프라 비용 절감
 - 제약: 무료 API 호출 건수 제한, 응답 지연 가능성
- 제품화를 고려할 경우:
 - Hugging Face API의 유료 플랜 또는 자체 모델 호스팅(Inference Endpoint, GPU 서버 구축) 필요
 - 실시간 대량 처리와 보안 강화를 위해 유료 클라우드 인프라, WAF, SMS API 연동 등이 추가 비용 요인으로 작용

동작환경 제약요건

- 안드로이드 전용 앱으로 설계 → iOS 기기에서는 사용 불가.
- 백엔드 서버는 Spring Boot + MySQL (Docker 컨테이너) 환경에서 동작하도록 제한.
- AI 분석 모듈은 텍스트 기반 LLM API 활용을 가정하므로, 대규모 이미지/음성 데이터는 처리 불가.
- 네트워크 연결이 불안정하거나 오프라인 환경에서는 서비스 동작이 제한됨.

개발환경 제약요건

- 개발 인력: 안드로이드, 백엔드, AI 파트로 나누어 개발하지만 팀 규모가 작아 멀티태스킹 필수.
- 개발 기간: 학기 프로젝트/공모전 제출 일정에 따라 제한적.
- 도구/언어:
 - 백엔드: Java 17, Spring Boot, MySQL
 - 프론트엔드: Kotlin, Android Studio, Jetpack Compose
 - 협업 환경: GitHub, Notion, Docker
- 테스트 환경: 실제 SMS 수신/권한 처리는 Android Emulator가 제한적이므로, 일부 기능은 실기기 테스트 필수.

사회적·환경적 영향 및 법적 제약

- 사회성:

- 스미싱 피해 예방을 목적으로 하여 사회적 안전성에 기여할 수 있음.
- 다만, AI의 탐지 결과가 100% 정확하지 않으므로 과도한 경고(오탐지) 시 사용자 불편을 초래할 수 있음.
- 법적 제약:
 - 개인정보(전화번호, 문자 내용 등)를 서버에 저장·분석할 경우, 개인정보보호법 및 정보통신망법을 준수해야 함.
 - 상용화 단계에서는 SMS 수집 및 처리에 대한 사용자 동의 절차가 반드시 필요.
- 윤리적 문제:
 - AI 모델의 판단 근거가 불투명할 경우 책임소재 불분명 문제가 발생할 수 있음.
 - 따라서 사용자에게는 “위험 점수 + 근거 요약”을 함께 제공하여 투명성 확보 필요.

L

● 개발 환경 :

1. 하드웨어
 - 개발용 노트북(Mac/OS / Windows 혼용 ,RAM 16GB 이상)
 - GoogleColab LLM 구동 전용 (GPU)
 - 서버: AWS EC2 무료 티어 (Ubuntu 24.04)
2. 소프트웨어 환경
 - 백엔드: Java 17, Spring Boot 3.x, JPA, MySQL (Docker 컨테이너)
 - 프론트엔드/클라이언트: Kotlin, Android Studio, Jetpack Compose
 - AI 분석 모듈: Hugging Face Transformers API, OpenAI GPT 계열, RAG(ElasticSearch 또는 Pinecone)
 - 협업 툴: GitHub, Notion, Slack, Figma
 - 테스트 환경: Android Emulator + 실기기 테스트

기대효과	● 기대효과 : 1. 개인적 측면 • 스미싱 피해 예방: 사용자가 메시지를 수신한 즉시 위험 여부와 이유를 확인할 수 있어, 피해 가능성을 크게 낮춤. • 심리적 안정감 제공: 불확실한 메시지에 대한 불안감을 줄이고, 사용자가 능동적으로 대처할 수 있게 함. • 편리성 향상: 차단·신고·은행 지급정지 등 필요한 조치를 앱 내에서 원스톱으로 처리 가능. 2. 사회적 측면 • 보안 사고 감소: 개인 금융사기 및 개인정보 유출 건수를 줄여 사회적 비용 절감. • 취약 계층 보호: 시니어·청소년 등 디지털 보안에 취약한 사용자의 안전망 강화. • 신뢰 회복: 보안에 대한 사회적 신뢰를 높이고, 모바일 환경의 안전한 이용 확산. 3. 기술적 측면 • LLM 적용 사례 확대: LLM이 단순 대화가 아닌 보안 영역에도 적용될 수 있음을 증명. • 지속 학습·적응성: 새로운 유형의 스미싱 패턴도 LLM과 RAG 기반으로 빠르게 학습·대응 가능. • 실시간 처리 기술: 모바일 단말-서버 연동을 통해 저지연(저딜레이) 탐지 구조 구현. 4. 산업/기관적 측면 • 금융사·통신사 협력 기반 마련: 금융사/통신사와 연계해 피해자 지원 체계를 강화 가능. • 기관 대응 효율화: KISA, 경찰청 등 보안 기관이 실시간 위협 데이터를 수집·활용해 신속한 대응 가능. • 시장 확장성: 초기에는 개인 대상 서비스로 시작해, 추후 기업 보안 솔루션으로 확장 가능.
------	---

추진 일정

● 세부 작업에 대한 간트차트 :

내용	기간	담당자
초기 세팅	9월 22일 ~ 28일	모두
와이어 프레임 및 기능명세서 작성	9월 22일 ~ 28일	현우
DB 설계	스프린트 전까지	찬혁
1차 스프린트	10월 3일 ~ 10 12일 (추석기간)	모두
2차 스프린트	중간고사 이후 ~ 11월 16일	모두
QA	11월 17일 ~	모두
최종 발표 자료 준비	11월 24일 ~	모두

● 세부 작업 별 구성원의 역할 :

역할	이름	비고
PM	임현우	
안드로이드	조효동	
백엔드	윤찬혁	
AI	임현우	

	항목	세부내용	예상(달성)시기
성과 창출 계획	Github	https://github.com/CSID-DGU/2025-2-DES4015-Fremen-02	~ 25년 12월
	논문게재 및 참가		
	SW등록		
	특허출원		
	시제품 (스토어에 등록)		