

지산학캡스톤디자인 최종보고서

학생 팀별 작성용

과제 수행원 현황						
수행 학기	■ 2025년 9월~2025년 12월					
프로젝트명	■ LLM 기반 스미싱 탐지 서비스					
팀명	■ Fremen					
	학과	학번	성명	성 별	연락처	E-mail
팀장	정보통신공학과	2021112061	임현우	남	010-3098-1575	dlagusdn0218@gmail.com
팀원	정보통신공학과	2021112040	윤찬혁	남	010-4803-5079	ych758@naver.com
	정보통신공학과	2021112092	조효동	남	010-3223-9978	whgyehdjhd@naver.com
지도교수	교과목명	■ 지산학캡스톤디자인				
	소속	■ 소프트웨어교육원				
	성명	■ 이길섭 교수				

보고서					
작품명 (프로젝트명)	LLM 기반 스미싱 탐지 서비스				
# Key Words	LLM	스미싱 탐지	RAG	실시간 분석	하이브리드 AI
1. 개발동기/ 목적/ 필요성 및 개발 목표	디지털 금융 환경의 급격한 발전으로 모바일 메신저와 문자 서비스는 일상생활의 핵심 소통 수단으로 자리 잡았습니다. 그러나 이를 악용한 스미싱(Smishing) 공격 또한 날로 지능화·고도화되고 있습니다. 기존의 스미싱 차단 시스템은 대부분 단순 키워드 매칭이나 블랙리스트 필터링 방식에 의존하고 있어, 변칙적인 신종 공격 패턴에 대응하는 데 구조적인 한계를 드러내고 있습니다. 이러한 문제의식은 크게 두 가지 기술적 난제로 요약됩니다. 첫째, 지능형 난독화(Obfuscation) 기법의 확산입니다. 공격자들은 보안 시스템의 탐지를 회피하기 위해 C&SIP와 같은 유사 특수문자 혼합, 텍스트의 이미지화				

(Image-based Smishing) 등 다양한 난독화 기법을 사용합니다. 기존의 텍스트 분석 기반 필터는 이러한 시각적 변형을 인식하지 못해 무력화되는 경우가 빈번합니다.

둘째, 문맥(Context) 이해 부재로 인한 오탐지(False Positive) 및 미탐지(False Negative) 문제입니다. 단순 키워드 필터링은 "택배 도착", "결제 승인"과 같은 정상적인 알림 문자를 스미싱으로 오인하여 사용자에게 보안 피로도(Security Fatigue)를 유발합니다. 반대로, 긴급한 상황을 연출하는 정교한 사회공학적인(Social Engineering) 공격 문구는 맥락을 파악하지 못해 차단하지 못하는 취약점이 존재합니다. 따라서 본 프로젝트는 서버 중심의 수동적 방어를 넘어, 모바일 디바이스의 엣지 컴퓨팅 능력과 LLM의 고도화된 문맥 이해 능력을 융합한 새로운 패러다임의 능동적 스미싱 방어 시스템을 제안합니다.

또한, 본 프로젝트의 궁극적인 목표는 다음과 같습니다

첫째, 온디바이스 기반 난독화 해제 및 선처리 구현:


문자 수신 즉시 디바이스 백그라운드 환경에서 YOLO(Object Detection) 및 OCR(광학 문자 인식) 기술을 가동합니다. 이를 통해 특수문자가 섞인 텍스트나 이미지 속 텍스트를 정상적인 언어 형태로 정제(Normalization)하여, 기존 필터링 기술을 우회하려는 공격자의 난독화 시도를 선제적으로 무력화합니다.

둘째, LM 기반 문맥 이해 및 근거 제시:

경량화된 KoBERT/KoBART 분류 모델과 RAG(검색 증강 생성) 기술이 적용된 LLM을 연동하여 문자의 의도, 유형, 위험도를 다각도로 분석합니다. 단순히 위험 여부만 알리는 것을 넘어, "왜 이 문자가 위험한지"에 대한 구체적인 근거를 제시함으로써 사용자의 보안 신뢰도를 높이고 능동적인 대처 능력을 향상시킵니다.

2. 최종결과물 소개

1. 아키텍처 다이어그램



• **Client Side – 실시간 문자 수집 및 1차 전처리**

클라이언트는 기기 내 SMS Hook을 통해 실시간으로 문자를 수집합니다.

수집된 문자는 기본적인 패턴 검사(전화번호/URL 포함 여부, 단문 안전 패턴 등)를 거쳐 On-Device AI 모듈로 전달됩니다.

불필요한 개인정보는 즉시 마스킹 처리하여 서버로 전달되는 데이터의 민감성을 최소화하도록 설계하였습니다.

• **On-Device AI – 문자 이해를 위한 기본 분석 모듈**

클라이언트 디바이스에는 경량화된 AI 모듈이 탑재되며, 다음 기능들을 수행합니다.

- **Text-to-Image 변환 및 OCR**

일부 문자 서비스(특히 스팸·메신저 피싱)는 이미지를 텍스트로 교묘히 섞어 전달하는 경우가 있어, 문자 내 이미지가 존재할 경우 YOLO 기반 객체 검출과 OCR로 텍스트를 보강합니다.

- **NLP (DistilKoBERT):**

간단한 문장 구조 분석, 토큰화 등의 사전 NLP 처리를 로컬에서 수행하여 서버가 처리해야 할 연산량을 줄입니다.

- **Federated Learning 지원:**

로컬에서 발생한 모델 사용 통계를 기반으로 미세한 파라미터 업데이트(Gradient Delta)를 생성하고 서버로 전달할 수 있는 구조를 고려해 설계되었습니다.

분산 학습 시 개인 데이터는 절대 서버로 전송되지 않으며, 모델 파라미터 변화만 공유되는 형태를 채택했습니다.

이 단계에서 전처리된 텍스트는 JSON 형태로 서버로 안전하게 전송됩니다.

• **Server Side – 데이터 관리 및 글로벌 모델 업데이트**

서버는 다음과 같은 핵심 기능을 수행합니다.

- **사용자 인증 및 요청 검증**

클라이언트 단에서 전송된 요청의 신뢰성을 확인하고 위·변조 여부를 검사합니다.

- **문자 데이터 저장 및 관리**

분석에 필요한 최소 정보만 DB에 저장하며, URL·연락처 등은 추가적으로 해싱 또는 마스킹 처리하여 보관합니다.

- **모델 파라미터 통합(FedAvg Aggregator)**

여러 사용자의 On-Device 업데이트 값(Gradient Delta)을 집계해 글로벌 모델을 재학습시키는 구조를 갖추고 있습니다.

이 과정은 주기적으로 실행되며, 서버는 개별 사용자의 원본 데이터를 전혀

수집하지 않는다는 점에서 보안성을 강화합니다.

이후 정제된 텍스트는 AI Server 모듈로 전달됩니다.

• **AI Server Side – KoBERT 분류 및 RAG-LLM 분석**

AI 서버는 문자 위험도 분석을 담당하는 핵심 모듈입니다.

• **KoBERT 스미싱 분류기**

Fine-tuning 된 KoBERT 모델은 입력 문자에 대해 NORMAL/SMISHING 여부와 스미싱 확률을 산출합니다. 확률값은 내부 기준에 따라 SAFE, CAUTION, DANGEROUS 의 3 단계 위험도로 재해석됩니다.

• **RAG 기반 위험 근거 검색**

KoE5 Embedding 모델을 이용해 입력 문장과 스미싱 유형 지식베이스(KB)의 문서를 벡터화하고, 의미적 유사도가 높은 문서 3 개를 검색합니다.

KB 는 국내 스미싱 유형(세금 환급, 택배 사칭, 금융 대출, 메신저 피싱, 기관 사칭 등)과 최신 보안 가이드(KISA)를 기반으로 구성되어 있습니다.

• **LLM Risk Reasoning Module**

KoBERT 결과 + RAG 검색 결과 + 사용자 입력 문장을 조합하여

“위험 여부 → 판단 근거 → 사용자 행동 지침”의 구조로 설명을 생성합니다.

LLM 의 오류나 응답 지연을 대비하여, 실패 시 KB 기반의 Fallback 문장을 제공하는 로직도 포함하였습니다.

AI Server 는 최종 결과를 하나의 JSON 으로 묶어 API Gateway 를 통해 반환합니다.

• **LLM Risk Reasoning Module – 최종 설명 생성 및 해석 가능성 확보**

이 모듈은 사용자에게 단순한 분류 결과가 아닌 “설명 가능한 보안 진단(Explainable AI)”을 제공합니다.

- KoBERT 예측 결과(확률·위험도)
- RAG 유사 문서(위험 패턴·예방법 포함)
- LLM 최종 설명 문장

이 세 요소가 조합되어 사용자가 직관적으로 이해할 수 있는 형태로 제시됩니다.

• **DBMS – 사용자 로그 및 모델 버전 관리**


분석 과정에서 생성된 최소한의 로그 정보(모델 버전, 요청 시간, 위험 등급)를 저장하며,

모델 성능 추적 및 향후 글로벌 업데이트(FedAvg)의 근거로 활용됩니다.

문자 원문은 저장하지 않거나, 보안 정책에 따라 해싱·마스킹된 형태로만 관리하여

개인정보 노출 위험을 원천적으로 차단합니다.

2. 유스케이스



• 변형된 스팸 문자 수신 흐름

사용자는 일반적인 문자 수신 과정에서 스팸·피싱 문자를 그대로 전달받습니다. 본 시스템은 사용자가 별도로 조작하지 않아도, 문자 수신 시점을 트리거로 하여 자동으로 분석 절차가 시작되도록 설계되었습니다.

• Main 기능 - 자동 문자 감지 및 스미싱 검사

사용자가 앱에 백그라운드 권한을 허용하면, 시스템은 수신된 문자 내용을 실시간으로 감지합니다.

감지된 문자는 즉시 스미싱 검사 AI로 전송되며, AI는 위험 여부와 그 근거를 분석합니다.

AI 분석이 완료되면, 시스템은 결과와 설명을 사용자에게 푸시 형태로 전달하여 즉각적인 대응이 가능하도록 하였습니다.

• 경고 알림 기능 - 실시간 위험 안내 및 근거 제공

AI가 분석한 결과가 위험 또는 의심 단계일 경우, 사용자에게 경고 알림이 발송됩니다.

알림에는 스미싱 유형, 위험 판단 근거, 조치 가이드가 포함되어 있어 사용자가

문자에 포함된 위험 요소를 쉽게 파악할 수 있습니다.

이 기능은 사용자가 추가 조작 없이도 실시간으로 보호받을 수 있도록 돕습니다.

• Sub 기능 - 친구 관리 및 차단 번호 관리

부가 기능으로 사용자 지정 기반의 필터링 기능을 제공합니다.

친구 관리 기능을 통해 신뢰할 수 있는 번호는 자동으로 안전 대상으로 분류하며, 차단 번호 관리 기능을 통해 사용자가 특정 발신자를 직접 차단할 수 있어 맞춤형 보안 환경을 제공합니다.

이 기능은 스팸싱뿐 아니라 원치 않는 광고나 스팸 메시지 차단에도 활용됩니다.

• 사용자 관리 - 회원가입 및 인증 흐름

비회원은 앱 설치 후 회원가입 절차를 통해 서비스를 이용할 수 있습니다.

회원가입 후에는 사용자 인증을 통해 각 사용자의 고유 환경을 설정하고, 개인화된 모델 업데이트 및 로그 관리가 가능해집니다.

사용자 인증 과정은 안전한 세션 관리 및 암호화 기술을 기반으로 진행되며, 개인정보 노출을 최소화하도록 설계되었습니다.


• 회원 사용자 흐름 - 문자 감지 → 분석 → 알림으로 이어지는 전체 경로

회원은 문자 수신 즉시 앱이 자동으로 이를 감지하고, 스팸싱 검사 AI를 통해 분석이 이루어집니다.

분석 후 사용자에게 결과가 반환되며, 필요 시 경고가 즉시 표시됩니다.

이 일련의 과정은 사용자 개입을 최소화하고, 스팸싱 감지 속도를 극대화하기 위한 구조입니다.

3. 시퀀스 다이어그램



• **사용자 → On-Device AI: 분석 요청(dispatch)**

사용자가 문자 분석을 요청하면, 앱은 해당 문자 데이터를 온디바이스 AI 모듈로 전달합니다. 온디바이스 모듈은 초기 전처리 및 위험 패턴 추출을 위해 여러 단계의 로컬 분석을 수행합니다.

• **On-Device AI 내부 처리: Test-to-Image → Object Detection → OCR 순차 수행**

온디바이스 AI 는 먼저 문자 내용을 이미지 형태로 변환한 뒤(Text-to-Image),YOLO 기반 객체 탐지(Object Detection)를 통해 URL·전화번호·금융 용어 등 의심 요소를 추출합니다.

추출된 정보는 OCR 단계에서 텍스트로 재해석되어, 서버가 분석하기에 적합한 형태로 정제됩니다. 이 일련의 과정은 디바이스 내부에서 수행되어 프라이버시를 보장하며 서버 트래픽을 최소화합니다.

• **On-Device AI → Server-Side AI: 분석 데이터 전달(dispatch)**

정제된 정보는 서버 사이드 AI 모듈로 전송되며,이 모듈은 사용자의 디바이스 환경과 서버 모델 간 동기화가 필요한 경우 추가 메타데이터를 포함해 전달받습니다.

• **Server-Side AI: Preprocessing 수행 후 Backend 로 전달**

서버 사이드 AI 는 수신된 데이터를 KoBERT 모델이 처리할 수 있는 형태로 다시 전처리합니다. 이 단계에서 토큰화, 특수문자 정규화, 모델 입력 형태 변환 등이 이루어집니다. 전처리가 완료되면 Backend 로 분석 요청을 전달합니다.

• **Backend: KoBERT 분류 실행 → RAG 근거 검색 수행**

Backend 는 파인튜닝된 KoBERT 모델을 활용해 입력 문자의 스미싱 여부를 예측합니다. 이후 예측 결과에서 추출된 키워드와 위험 패턴을 기반으로 RAG 검색을 수행하여, 가장 관련성이 높은 KB 문서를 식별합니다. 이 과정은 스미싱 탐지의 정확도를 높이고, LLM 이 설명을 생성할 때 활용할 근거를 제공합니다.

• **Backend → Server-Side AI: 분석 결과 반환(return)**

KoBERT 분석 결과와 RAG 기반 근거 문서가 Server-Side AI 로 전달됩니다. Server-Side AI 는 이를 사용자 친화적인 구조로 가공하여 디바이스로 전송할 준비를 합니다.

• **Server-Side AI → On-Device AI: 결과 반환(return)**


정리된 결과는 온디바이스 모듈로 전달되며, 디바이스는 이를 UI 에 적합한 형태로 변환합니다.

• **On-Device AI → 사용자: showResult() 실행**

최종적으로 앱 화면에 분석 결과가 표시됩니다.

사용자는 '정상/의심/위험' 등급, 위험 근거, 추천 행동 가이드를 직관적으로 확인할 수 있습니다.


4. 알고리즘 플로우차트



시퀀스 다이어그램 내용과 동일합니다.

5. 인터페이스


#1.초기화면




#2.메세지 분석화면




#3.문자 백그라운드 감지



#4. 최근 알림 리스트



#5. 문자 분석 결과 상세 내용



6. 카카오뱅크 'AI 스미싱 문자 확인' 서비스와의 비교 분석

(ㄱ) 서비스 제공 범위

- 카카오뱅크**
 카카오뱅크 앱 안에서 제공되는 보안 기능으로, 사용자가 다른 메신저, 문자 앱에서 받은 내용을 복사하여 붙여넣었을 때 해당 문장이 스미싱인지 여부를 판단해 준다. 주로 계좌 이체, 대출, 인증 문자 등 금융 거래를 사칭하는 스미싱 문자를 중심으로 설계된 서비스이다.
- Fremen**
 특정 금융앱에 국한되지 않고, 스마트폰 전체에서 수신되는 문자·메신저 메시지를 대상으로 실시간 분석을 수행한다. 은행 사칭뿐 아니라 택배, 공공기관, 단기 알바 사칭 등 다양한 유형의 스미싱을 한 번에 감지할 수 있어, 사용자의 일상 전반을 포괄하는 보안 레이어를 제공한다.


(ㄴ) 탐지 시점 및 동작 방식

- 카카오뱅크**
 카카오뱅크의 'AI 스미싱 문자 확인' 서비스는 사용자가 받은 문자 중 의심되는 내용을 직접 카카오뱅크 앱에 복사·붙여넣기 했을 때 동작한다. 앱에 붙여넣은 문장을 기준으로 '스미싱 위험이 높은 문자 / 안전한 문자 / 단순 스팸 / 판단 불가'와 같은 결과와 판단 근거를 보여주는 사용자

요청형(수동 검사) 서비스이다.

- Fremem

Fremem 은 별도의 복사-붙여넣기 과정 없이, 스마트폰으로 메시지가 수신되는 시점에 자동으로 분석이 이루어지도록 설계한다. 안드로이드 단말에서 알림을 감지해 텍스트를 서버로 전송하고, LLM 기반 분석 결과를 바탕으로 정상 / 주의 / 위험 등급과 설명을 바로 띄워 주는 실시간 자동 탐지 방식이라는 점에서 카카오뱅크와 차이가 있다. 또한 메시지를 직접 붙여넣어 탐지하는 기능도 포함한다.



(ㄷ) AI 활용 방식과 설명 체계

- 카카오뱅크

금융사 최초로 인공지능 기반 탐지 모델을 일부 적용하여 단순 패턴 탐지보다 높은 정밀도를 확보했다는 점에서 의의가 있다. 다만, 분석 결과는 주로 “위험한 문자이므로 주의하라”는 경고 중심으로 제시되며, 사용자가 메시지의 어떤 부분이 문제인지까지 세밀하게 설명받기는 어렵다.

- Fremem

범용 한국어 LLM 과 RAG(Retrieval-Augmented Generation)를 결합해 문맥 기반 분석 + 근거 설명을 함께 제공한다. 각 메시지에 대해 “어떤 기관을 사칭하는지”, “URL 이 공식 도메인과 어떻게 다른지”, “급박한 상황을 과장해 금전 송금을 유도하는 문장 구조인지” 등 위험 요소를 자연어로 풀어 보여 주어, 사용자가 스스로 메시지를 이해하고 판단할 수 있도록 돕는다.

(ㄹ) 사용자 경험 및 확장성

- 카카오뱅크

금융 거래 과정에서 안전한 이체와 결제를 돕는 데 최적화되어 있으며, 카카오뱅크 고객에게는 강력한 부가 보안 수단이 된다. 그러나 서비스가 자사 앱 내부에 한정되어 있어, 다른 금융앱이나 일반 문자에서 발생하는 위협까지는 직접 보호하지 못한다.

• Fremen

특정 은행이나 통신사에 종속되지 않는 독립적인 보안 레이어를 지향하며, 향후 통신사 스팸 차단 서비스, 금융앱, KISA 신고 시스템 등과 연동해 하나의 통합 대응 허브로 확장될 수 있다. 사용자는 위험 알림 화면에서 바로 번호 차단, 신고, 공유 등 후속 조치를 이어갈 수 있도록 설계함으로써, 탐지와 대응이 끊기지 않는 원스톱 경험을 제공한다.

(㉠) 종합

- 카카오뱅크의 'AI 스미싱 문자 확인' 서비스가 금융앱 내부에서의 안전한 거래에 강점을 가진다면, Fremen 은 그 장점인 "설명 가능한 경고 화면"을 계승하면서도 동작 범위를 스마트폰 전역으로 넓히고, 범용 LLM-RAG 기반 문맥 분석을 통해 다양한 스미싱 유형을 수신 단계에서 선제적으로 막는다는 점에서 차별화된 가치를 가진다.

구분	주요 서비스	탐지 방식	한계점	Fremen 차별성
카카오뱅크	클릭 시 경고 안내 / AI 스미싱 문자	내부 보안 DB + ML 일부 적용	앱 내부 한정 단일 플랫폼 중심 사용자가 요청 시 동작	단말기 전체 문자 분석 및 대응 가능
Fremen (본 프로젝트)	실시간 LLM 기반 탐지 및 설명	룰 + 문맥 혼합 분석	-	실시간 탐지 사용자 이해형 해설 즉시 대응 가능

1. 프로젝트 진행과정

(㉡) 문제 인식 및 아이디어 도출

모바일 메신저와 문자 서비스가 일상화되면서, 이를 악용한 스미싱 공격이 지능화·고도화되고 있음을 확인하였다. 기존 스팸 필터는 키워드·블랙리스트에 의존해 글자를 특수문자로 꼬아 쓰거나, 사람을 속이는 표현에는 잘 막지 못하고, 사용자는 "왜 위험한지"를 이해하지 못한 채 경고만 받는 한계를 가진다. 이러한 문제를 해결하기 위해, LLM 기반 문맥 이해와 온디바이스 실시간 탐지를 결합한 스미싱 방어 서비스를 프로젝트 주제로 선정하였다.

(㉢) 요구사항 정의 및 아키텍처 설계

사용자가 별도의 앱을 켜지 않아도 문자 수신 시 자동으로 분석·경고가 이뤄지도록, 안드로이드 단말에서 알림을 감지하고 서버로 분석을 요청하는 흐름을 요구사항으로 정의하였다. 서버에서는 스미싱 여부뿐 아니라 유형, 위험도, 근거 문장을 함께 반환해 "설명 가능한 보안"을 실현하도록 설계하였다. 이를 위해 안드로이드 앱 - Spring Boot 백엔드 - LLM 기반 AI 서버로 구성된 3 계층 하이브리드 아키텍처를 설계하였다.

3. 프로젝트
추진 내용

(ㄷ) 역할 분담 및 일정 수립

팀은 안드로이드(프론트엔드), 백엔드, AI 파트로 역할을 명확히 분리하여 병렬 개발이 가능하도록 하였다. 프론트는 앱 화면과 알림 감지, 백엔드는 API 서버와 DB, AI 는 분류 모델 및 LLM 연동을 담당하였다. 간트차트를 작성해 아이디어 구체화 → 설계 → 구현 → 연동 → 테스트 → 최종 발표 준비의 단계별 일정을 수립하고, 주 단위 회의와 GitHub 및 Notion 을 통해 진행 상황을 공유하였다.

2. 프로젝트 구현과정

1. 개념 설계

(ㄱ) 전체 처리 흐름

본 서비스는 “문자 수신 시 자동 분석 → 위험도 및 근거 제공”을 목표로 한다. 안드로이드 단말에서 알림을 감지하여 텍스트와 최소 메타데이터만 추출·정제한 뒤 서버로 전송하고, 서버에서는 한국어 분류 모델(Kobert)과 LLM/RAG 를 이용해 스미싱 여부, 유형, 위험도를 판단한다. 이후 “왜 이 문자가 위험한지”에 대한 근거 문장과 함께 결과를 앱으로 반환하여, 사용자가 직관적으로 이해할 수 있도록 한다.

(ㄴ) 위험도 및 출력 형식

메시지는 정상 / 경고 / 위험 세 단계로 나누어 표시되며, 도박·대출·기관 사칭·지인 사칭 등 카테고리도 함께 제공된다. 각 단계는 모델이 산출한 위험 점수와 URL 형태, 개인정보 요구 여부, 긴급 압박 표현 사용 여부 등을 종합해 결정된다. 최종 출력은 위험도 배지, 유형 라벨, 핵심 위험 요소, 추천 후속 조치(직접 은행 앱 접속, 공식 고객센터 문의, 신고 권장 등)를 포함하는 형식으로 설계하였다.

2. 상세 설계

(ㄱ) 안드로이드 클라이언트

- 알림 감지 및 전처리

NotificationListenerService 를 이용해 문자·메신저 알림을 감지하고, 제목·본문·발신 번호·수신 시각 등 최소한의 정보만 추출한다. 단말에서 계좌번호·주민등록번호 패턴 등 민감 정보는 마스킹하여 서버에 직접 노출되지 않도록 했다.

- **화면 구조**

초기화면 – 메시지 분석 화면 – 최근 알림 리스트 – 분석 결과 상세 화면으로 이어지는 플로우를 Compose 기반으로 설계하였다. 상세 화면에서는 위험도(색상/아이콘), 스미싱 유형, 의심 키워드, LLM 이 생성한 설명, 후속 조치 버튼을 한 화면에서 확인할 수 있도록 구성하였다.

- **실시간 경고 UX**

분석 결과가 "경고" 이상일 경우, 앱을 열지 않아도 상단 알림 또는 오버레이 형태로 위험 여부를 즉시 알려 사용자가 링크를 누르기 전에 경계할 수 있도록 하였다.

(L)백엔드(Spring Boot)

- **이중 필터링 도입**

모든 문자를 AI 로 전송할 경우 발생하는 비용과 속도 저하를 막기 위해, 서버 단에서 **1 차 를 베이스 필터링(Rule-based Filtering)**을 선행한다. "김밥", "ㅇㅇ" 등 정보량이 적거나 안전한 단문은 AI 호출 없이 즉시 '안전'으로 판별하여 API 응답 속도를 0.01 초 대로 단축하고 불필요한 AI 리소스 낭비를 방지했다.

- **REST API 연동:**

POST /api/v1/analyze 엔드포인트를 통해 1 차 필터를 통과한 의심 문자(URL, 숫자 포함 등)만 Python AI 서버로 비동기(WebClient) 전송하며, 분석된 위험도(Score)를 기반으로 CRITICAL, CAUTION, SAFE 3 단계 등급을 산정하여 반환한다.

(ㄷ) AI 분석 엔진 상세 설계 및 구현 방식

- **모델 기반 위험도 산정 구조**

KoBERT 분류 모델은 입력된 문자 메시지에 대해 '정상(NORMAL)' 또는 '스미싱(SMISHING)'을 예측하며, Softmax 확률을 통해 스미싱 가능성을 정량적으로 계산합니다.

예측된 스미싱 확률은 내부 기준에 따라 SAFE, CAUTION, DANGEROUS 3 단계로 구분되며, 이 값은 이후 RAG 검색 및 LLM 설명 생성의 핵심 입력으로 활용됩니다.

- **RAG 기반 지식 문서 매칭(KoE5 Embedding)**

사용자가 입력한 문장을 KoE5 문장 임베딩으로 변환한 뒤, 사전에 구축한 스미싱 위험 유형 지식베이스(KB)와 의미적 유사도를 계산합니다.

KB는 기관 사칭, 세금 환급 사기, 택배 배송조회 사칭, 금융 대출 사기, 메신저 피싱 등 국내 실제 사례를 기반으로 구성되어 있으며, 각 문서에는 위험 패턴·설명·예방법이 포함됩니다.

시스템은 이 중 상위 2~3 개의 문서를 검색해 KoBERT 결과와 함께 LLM에 전달합니다.

- **LLM 기반 설명 생성 구조**

LLM은 KoBERT 확률, RAG 검색 결과, 사용자 입력문을 종합해 “위험 여부 → 판단 근거 → 행동 지침” 순서로 이해하기 쉬운 분석 보고서를 생성합니다.

프롬프트는 통일된 출력 형식을 지정하여, 서비스 전용으로 최적화된 설명 문장을 생성하도록 설계하였습니다. 또한 LLM 응답 실패 시에는 KB의 기본 설명을 활용하는 Fallback 로직을 제공하여 안정성을 강화했습니다.

- **최종 출력 및 JSON 응답 구조**

AI 서버는 KoBERT 분류 라벨, 스미싱 확률, 위험도(Lv.1~3), 연관성이 높은 KB 문서, 그리고 LLM이 생성한 설명을 하나의 JSON 형태로 통합해 반환합니다.

클라이언트는 이를 그대로 사용자에게 표시하여, 단순 탐지를 넘어 “왜 위험한지”를 함께 제공하는 설명 가능한 보안 기능을 구현할 수 있습니다.

3. 시스템 전체 동작 흐름 요약

- I. 사용자 메시지 입력
- II. KoBERT 분류 및 스미싱 확률 계산
- III. KoE5 임베딩 기반 KB 문서 검색
- IV. KoBERT 결과 + KB 근거를 LLM에 전달
- V. LLM이 위험 분석·근거·대응 방법을 생성
- VI. AI 서버가 JSON 형태로 통합 응답 제공


이러한 6 단계의 구조를 통해 본 시스템은 정밀한 탐지 능력과 직관적인 설명력을 동시에 갖춘 고도화된 보안 분석 엔진으로 동작합니다.

4. 기대효과	1. 경제적 측면 (ㄱ) 온디바이스(On-device) 기술과 경량화된 아키텍처를 통한 혁신적인 비용 절감입니다. 기존의 중앙 서버 집중형 보안 시스템은 방대한 트래픽 처리를 위해 고비용의 서버 인프라를 요구합니다. 반면, 본 시스템은 모바일 기기 내에서 난독화 해제 및 1차 분석을 수행하는 엣지 컴퓨팅(Edge Computing) 기술을 도입하여 서버 부하를 획기적으로 낮췄습니다. 이를 통해 서비스 운영 비용을 최소화하고, 별도의 하드웨어 도입 없이 소프트웨어만으로 고효율 보안 환경을 구축할 수 있어 경제적 효용성이 매우 높습니다. (ㄴ) 오탐지(False Positive) 감소를 통한 사회적 비용 최소화입니다. 기존 시스템의 잦은 오탐지는 사용자에게 불필요한 대응 비용을 발생시킵니다. 본 프로젝트는 LLM의 정교한 문맥 분석을 통해 정상 문자와 스미싱을 정확히 구분하여 불필요한 리소스 낭비를 막습니다. 더 나아가, 스미싱으로 인한 개인의 금전적 피해와 이에 따른 금융기관의 사후 처리 비용, 국가적 차원의 수사 비용 등 막대한 사회적 손실을 선제적으로 차단하는 경제적 파급 효과를 가집니다. 2. 사회적 측면 (ㄱ) 디지털 취약 계층을 위한 '설명 가능한 보안(XAI)' 실현 및 디지털 리터러시 향상입니다. 기존의 "위험하니까 차단함" 식의 일방적인 통보는 IT 지식이 부족한 고령층이나 디지털 소외 계층에게 막연한 불안감을 주었습니다. 본 시스템은 RAG(검색 증강 생성) 기술을 활용하여 "왜 이 문자가 위험한지"에 대한 명확하고 쉬운 근거를 제시합니다. 이는 단순히 사용자를 보호하는 것을 넘어, 사용자가 스스로 위협을 인지하고 학습하게 함으로써 사회 전반의 보안 의식과 디지털 리터러시(Digital Literacy)를 향상시키는 교육적 가치를 제공합니다. (ㄴ) 능동적 방어 체계를 통한 정보 격차 및 불평등 해소입니다. 복잡한 보안 앱을 찾아 실행하기 어려운 사용자들을 위해, 문자 수신 즉시 직관적인 오버레이(Overlay) 경고를 제공하는 능동적 방어 체계를 구축했습니다. 이는 기술적 장벽으로 인해 범죄의 표적이 되기 쉬운 취약 계층에게 평등한 수준의 디지털 안전망을 제공합니다. 기술이 사회적 불평등을 심화시키는 것이 아니라, 가장 필요한 곳에서 안전을 보장하는 포용적 도구로 기능하도록 하여 사회적 안전망 강화에 기여합니다.
5. 팀원 역할	1. 구성원 역할 - PM: 임현우 - 프론트: 조효동

- 백엔드: 윤찬혁

- AI: 임현우

2. 기술 스택



- 프론트 : Android Studio, Kotlin, Jetpack Compose, MVVM, Retrofit2

- 백 : Spring Boot

- AI : SKT KoBERT(스미싱 분류 모델), KoE5(RAG 기반 SentenceTransformer + KB 기반 검색 모델), 한국어 LLM

- 협업 툴 : Github, Slack, Notion

3. 간트차트

항목	세부 내용	세부 추진 일정(주)															담당자
		1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	
아이디어 선정	프로젝트 아이디어 선정 및 요구사항 정의	■	■														전체
기술 설계	시스템 아키텍처 설계		■	■													조효동
DB 아키텍처 구축	데이터베이스 구조 ERD 설계			■	■												임현우
API 명세 작성	시스템 기능을 위한 API 명세 작성			■	■												윤찬혁
기술 검토 및 설계	UI/UX 와이어 프레임 제작			■	■	■	■										임현우
개발 초기 세팅	백엔드, Android, AI 각 파트 별 프로젝트 초기세팅							■	■	■							파트별 담당
문서 작성	중간 발표 보고서 항목별 작성								■	■							파트별 담당
개발	백엔드, Android, 서버 각 파트별 기능 개발									■	■	■	■	■			파트별 담당
연동	프론트와 백엔드 간 연동										■	■	■	■			조효동, 윤찬혁
테스트	서버와 앱간 통합 테스트													■	■		조효동, 윤찬혁
최종 준비	최종 문서 작성 및 발표 준비														■	■	파트별 담당

- 아이디어 선정 : 임현우, 조효동, 윤찬혁

- 기술 설계 : 조효동

- DB 아키텍처 구축 : 임현우

- API 명세 작성 : 윤찬혁

- 기술 검토 및 설계 : 임현우

- 개발 : 임현우, 조효동, 윤찬혁

- 문서작성 : 임현우, 조효동, 윤찬혁

- 연동 : 조효동, 윤찬혁

- 테스트 : 임현우, 조효동, 윤찬혁

- 최종 발표 준비 : 임현우, 조효동, 윤찬혁

6. 참고문헌	[1] 카카오뱅크 기술연구소, "한국어 LLM 기반 스미싱 탐지와 금융 데이터 생성 연구", 카카오뱅크 기술 블로그, 2025. [2] 정아름, "더 안전한 금융거래를 지원하는 'AI 스미싱 문자 확인' 서비스", 카카오, 2025. [3] 카카오뱅크플러스, "생성형 AI 활용한 첫 서비스, AI 스미싱 문자 확인", 브런치, 2025. [4] 김완재, "IBK 기업은행, AI 기반 피싱 진단 강화... 비대면 금융보안 체계 전면 업그레이드", 일요주간, 2025. [5] 김예은, "'피싱수법 예방'... KISA-카카오뱅크 'AI 기반 스미싱 차단' 맞손", 뉴스 1, 2025. [6] 이종현, "[2025 AI 보안 솔루션 리포트] AI 보안 솔루션, 능동형 AI와 XAI로 진화", 보안뉴스, 2025.
7. 프로젝트 성과	Github 등록 링크 : https://github.com/CSID-DGU/2025-2-DES4015-Fremen-02
8. 첨부	1. 팀구성원이 함께 찍은 사진 